



Modelos de Clusterização e Classificação para Campanhas de Marketing em uma Plataforma de Delivery

Nesse projeto foram criados modelos de machine learning para realizar a segmentação de clientes e prever os clientes mais propensos a aceitar futuras campanhas



Matheus Resende

Follow

6 min read · 11 hours ago

Open in app ↗

Sign up


Sign in

Medium

Search

Write





Introdução

A segmentação de clientes é um dos pilares para o sucesso das plataformas de delivery, onde a variedade de perfis de consumidores e de estabelecimentos parceiros exige uma comunicação altamente direcionada. Modelos de machine learning podem analisar o histórico de pedidos, frequência de compras e preferências culinárias para identificar padrões de comportamento e criar grupos de clientes com características semelhantes. Essa abordagem permite que as campanhas de marketing sejam mais relevantes, oferecendo recomendações de restaurantes e promoções personalizadas que aumentam o engajamento e a taxa de conversão dos clientes.

Nesse projeto, a partir de dados disponíveis em um dataset do Kaggle, foram aplicados conceitos de estatística, programação, análise e ciência de dados para criar dois modelos de machine learning, um de clusterização e outro de classificação, aplicados em uma plataforma de delivery. O objetivo do primeiro modelo é realizar a segmentação de clientes da plataforma direcionada para campanhas de marketing. Já o segundo modelo utiliza

como base a segmentação realizada pelo primeiro para prever os clientes mais propensos a aceitar futuras campanhas.

Modelo de Clusterização

Cluster 0	Cluster 1	Cluster 2
Renda alta	Renda baixa	Renda média
Faz muitas compras	Faz poucas compras	Faz muitas compras
Gasta muito em compras	Gasta pouco em compras	Gasta moderadamente em compras
Provavelmente não tem filhos	Provavelmente tem filhos	Provavelmente tem filhos
Faz poucas compras com desconto	Faz algumas compras com desconto	Faz muitas compras com desconto
Visita pouco o site	Visita muito o site	Visita muito o site
Alta escolaridade	Único grupo que tem pessoas com escolaridade baixa	Alta escolaridade
Aceita campanhas facilmente	Difícilmente aceita campanhas	Pode aceitar campanhas
É cliente há menos tempo	É cliente há menos tempo	É cliente há mais tempo

Tabela 1: Grupos gerados pela segmentação de clientes.

Após a criação do modelo de clusterização foi possível realizar a segmentação dos clientes da empresa, conforme é possível ver na tabela 1. Dessa forma, observa-se claramente que o cluster 0 é o grupo de clientes que está mais propenso a aceitar campanhas. Assim é possível traçar o perfil de cliente buscado inicialmente, que no caso é uma pessoa com renda alta, que faz muitas compras e com altos valores, provavelmente não possui filhos, faz poucas compras com desconto, acessa pouco o site, possui uma alta escolaridade e é cliente da empresa há pouco tempo. Logo, a persona buscada no projeto é descrita detalhadamente e assim se torna possível direcionar as campanhas de marketing para o público exato que se busca. Além disso, um insight relevante que é possível observar, é que os clientes do cluster 2 também podem eventualmente aceitar campanhas, por isso podem ser uma opção caso a equipe de marketing da empresa deseje ampliar o alcance da campanha.




Imagem 1: Aplicação do K-means.

Em relação a parte técnica do projeto, o algoritmo selecionado para realizar essa segmentação de clientes foi o K-means. Esse é um dos algoritmos de machine learning não supervisionado mais utilizados em casos de agrupamento (clusterização). Esses tipos de algoritmos não possuem rótulos predefinidos, encontrando os padrões nos conjuntos de dados por conta própria. Seu funcionamento se dá, ao previamente realizar alguns tratamentos no conjunto de dados como pré processamento e redução de dimensionalidade, assim os dados são agrupados em grupos de forma que os pontos de cada grupo fiquem próximos entre si. Para isso cada grupo possui um ponto central, chamado de centróide, e para cada ponto do conjunto de dados é calculada a distância entre ele e cada centróide, selecionando a menor distância entre eles para assim definir a qual grupo o ponto pertence e realizar o agrupamento dos dados. Todo esse processo é ilustrado na imagem 1.




Imagem 2: Métodos do cotovelo e da silhueta.

Para a definição da quantidade de clusters que seriam usados nessa segmentação foram aplicados os métodos do cotovelo e da silhueta, conforme é possível ver na imagem 2. Dessa forma, foi possível definir que 3 clusters eram a quantidade ideal para esse projeto, já que ambos os métodos corroboram esse número com sua interpretação.


Get Matheus Resende's stories in your inbox

Join Medium for free to get updates from this writer.

Enter your email

Subscribe

E por fim, com base no número ideal de clusters, foram gerados histogramas e diagramas de caixa para identificar as personas de cada um dos grupos de clientes, conforme mostram as imagens 3 para os histogramas e 4 para os diagramas de caixa. Dessa forma, através da interpretação dos conceitos estatísticos dos gráficos, foi possível identificar as personas dos 3 grupos de clientes desse estudo de acordo com a tabela 1 apresentada anteriormente.






Imagem 3: Histogramas do modelo de clusterização.




Imagem 4: Diagramas de caixa do modelo de clusterização.

Modelo de Classificação

Já sobre o modelo de classificação para prever clientes propensos a aceitar futuras campanhas com base na segmentação realizada anteriormente, foram testados 4 algoritmos para avaliar suas performances num primeiro momento antes de selecionar o melhor e seguir para a próxima etapa para otimizar sua performance ao máximo. Nesse contexto de um projeto de classificação foram selecionados os seguintes modelos para a avaliação inicial: dummy classifier, árvore de decisão, regressão logística e KNN. Apenas para contextualizar sobre o dummy classifier já que os demais algoritmos são bem conhecidos, trata-se de um modelo simples usado apenas como referência nas avaliações das métricas, servindo como alerta caso alguma métrica dos outros modelos fique abaixo das obtidas por esse modelo.




Imagem 5: Comparação entre os modelos de classificação.

Após o treinamento dos modelos, foram gerados diagramas de caixa para avaliar suas performances, conforme é possível ver na imagem 5. Para a avaliação dos modelos foram usadas métricas como acurácia, precisão, recall, área sob a curva ROC, precisão média e tempo de processamento. Essas métricas foram escolhidas pois são as mais indicadas para modelos de classificação. Após uma avaliação cuidadosa das métricas selecionadas, o modelo escolhido para avançar para a otimização de sua performance foi o

de regressão logística, justamente por apresentar os resultados mais consistentes na avaliação.

Na etapa seguinte, de otimização do modelo selecionado, foi executado um pipeline de treinamento totalmente direcionado para o modelo de regressão logística. Nesse pipeline foi realizado o pré processamento das features para adequação dos seus dados ao treinamento, a seleção das features mais relevantes para o modelo, o balanceamento de classes no conjunto de dados, a validação cruzada nos dados de treino e teste, e por fim foi realizada a otimização de hiperparâmetros para encontrar a melhor combinação de variáveis visando a melhor performance possível do modelo.




Imagem 6: Comparação entre as performances inicial e final do modelo selecionado.

Na imagem 6, é apresentada a comparação entre as métricas do modelo de regressão logística antes e depois da aplicação da otimização de hiperparâmetros. Dessa forma, é possível ver a importância da aplicação dessa técnica já que praticamente todas as métricas avaliadas mostram que houve evolução em seus resultados.

Além disso, é importante citar que durante todo o projeto foram adotadas boas práticas para evitar que houvessem indícios de overfitting no modelo. Entre as principais ações que foram aplicadas podemos citar a seleção das

features mais relevantes para o modelo, o balanceamento de classes para manter o dataset com classes equilibradas, a validação cruzada para que o modelo tenha contato com diversas combinações de dados de treino e teste, e a otimização de hiperparâmetros para que fossem encontradas as melhores combinações possíveis das variáveis de treinamento do modelo. A aplicação de todas as medidas apresentadas reduz consideravelmente qualquer possibilidade de overfitting no modelo treinado.

Conclusão

Esse estudo evidencia como a combinação de modelos de machine learning de clusterização e classificação pode transformar a abordagem de marketing em plataformas de delivery, passando de apenas reativas para preditivas. Ao mapear perfis de clientes e antecipar comportamentos, a empresa está mais bem posicionada para desenvolver produtos, ofertas e estratégias que tenham sucesso com diferentes perfis de consumidores.

A grande questão é transformar os padrões identificados pelos modelos em estratégias práticas, com metas claras e indicadores de sucesso bem definidos. Ao alinhar essas iniciativas aos objetivos de negócio da empresa e engajar todas as áreas envolvidas, é possível não apenas melhorar a conversão de campanhas no curto prazo, mas também consolidar uma relação mais duradoura com os clientes visando o médio e longo prazo. Isso impacta positivamente os resultados da empresa e ajuda a construir uma base de clientes mais satisfeitos e fiéis a marca.

Technology

Artificial Intelligence

Machine Learning

Data Science

Data



Written by Matheus Resende

0 followers · 1 following

Data Scientist

Follow